Challenge Data

Prédiction des Performances d'Allocations d'Actifs

par QRT

Connectez vous à votre compte

Description

Challenge compétitif | Sciences économiques | Finance | Classification | Séries temporelles | 10Mo à 1Go | Niveau intermédiaire

Dates

Commencé le 22 janvier 2026

Contexte

Faire confiance, ou parier contre ?

Prediction des performances d'allocations d'actifs

Dans le monde du trading systématique, les allocations d'actifs sont omniprésentes - mais la qualité des signaux fait toute la différence.

Chaque jour, les traders sont submergés d'allocations candidates : des constructions de portefeuille fondées sur des signaux prédictif récents, des flux de liquidité, ou des shémas historiques. Certaines de ces allocations de portefeuille seront profitables lors de la prochaine session de trading. Certaines autres sous-performeront, ou pire, seraient perdantes de manière si consistente que parier contre serait le plus profitable.

Ce challenge se centre donc autour d'une question simple mais cruciale :

Pouvez-vous prédire si une allocation d'actifs donnée mérite d'être suivie, ou si à l'inverse il vaut mieux parier contre ?

Qu'est-ce qu'une allocation d'actifs ?

Une allocation d'actif peut être définie comme une méthode systématique de construction de portefeuille utilisant des signaux ou règles prédéfinies. Dans ce challenge, chaque allocation est définie par un vecteur de poids, positifs ou négatifs, définis chaque jour et tenus pour toute une session de trading. D'un jour à l'autre, une allocation peut rééquilibrer ses poids selon une certaine proportion, appelée « turnover », en fonction des règles utilisées pour les calculer. Les performances journalières d'une allocation d'actifs représentent les performances aggrégées des positions pondérées et rebalancées chaque jour.

Définition Mathématique

Pour un jour `t` , une allocation `S` , et `M` actifs dans un univers de trading, soient :

Les poids de l'allocation `S` au jour `t` :

$$w_{S,t} = (w_{S,t,1}, w_{S,t,2}, \ldots, w_{S,t,M})$$

La performance, souvent appelée rendement, d'un actif `i` du jour `t` au jour `t+1` :

$$r_{i,t+1}$$

Alors, le **rendement réalisé** d'une allocation `S` à `t+1` est donnée par :

$$r_{S,t+1} = \sum_{i=1}^{M} w_{S,t,i} * r_{i,t+1}$$

But

Chaque ligne du dataset représente **une journée *et* une allocation d'actifs**, matérialisée par son portefeuille de poids construit et rebalancé ce jour là.

Pour chaque ligne, les données représentent **le comportement historique de l'allocation correspondante rebalancée lors des 20 jours précédents** : ses performances historiques journalières, son comportement en liquidité (résumé en "volumes pondérés"), et son turnover médian.

Le but est d'utiliser cette empreinte historique pour prédire le **signe du rendement futur de cette allocation d'actifs** :

- Si un modèle prédit une performance positive, faire confiance à l'allocation et tenir ses poids pour la prochaine session.
- Si un modèle prédit une performance négative, parier contre l'allocation et jouer l'inverse de ses poids.

Métrique d'évaluation

La métrique choisie est l'**Accuracy**, qui détermine à quel point un modèle prédit correctement la **direction** (signe) de la performance future d'une allocation.

Pour chaque ligne `i` indexée par un timestamp `t` et une allocation `S` , il est attendu une prédiction du **signe** de la **vraie performance future** `r_i` pour le jour suivant :

- `1` si la prédiction est positive.
- `0` si la prédiction est négative.

Uniquement la capacité à prédire le **signe** est évaluée, pas la magnitude.

$$Accuracy = \frac{1}{N}\sum_{i=1}^{N} 1\,[sign(\hat{r}_i) = sign(r_i)]$$

$$Accuracy = \frac{1}{T*M}\sum_{t=1}^{T}\sum_{S=1}^{M} 1\,[sign(\hat{r}_{S,t+1}) = sign(r_{S,t+1})]$$

Avec:

- `N` le **nombre de lignes du dataset**
- `sign(x) = 1` Si `x > 0` , sinon `0`
- `1` La **fonction Indicatrice** (vaut 1 si la condition est vraie, 0 sinon)
- le **vrai rendement futur** d'une allocation `S` au jour `t` :

$$r_i = r_{S,t+1}$$

- la **prédiction du rendement futur** pour l'allocation `S` au jour `t` :

$$\hat{r}_i = \hat{r}_{S,t+1}$$

Description des données

Le dataset est sous forme de time series avec un multi-index (date, allocation).
Chaque ligne contient:

- **L'historique des performances sur les 20 derniers jours d'une allocation**
- **Le comportement de liquidité des 20 derniers jours de cette même allocation**
- **Son turnover médian sur les 20 derniers jours**
- **Un groupe d'appartenance anonymisé**
- **Son rendement futur**: La performance de l'allocation sur la prochaine session. **Les vraies performances sont données pour l'entrainement, mais l'évaluation sur le test set ne se fait que sur la capacité à prédire le signe.**

Colonnes

- `TS` Timestamp du snapshot (les dates ont été anonymisées, il n'y a pas de garantie de continuité même si les labels sont DATE_0001, DATE_0002, DATE_0003)
- `ALLOCATION` Nom de l'allocation (ALLOCATION_01 est la même entre date DATE_0001, DATE_0002 etc.)
- `RET_{i}` Avec i dans 1, ..., 20 - Le rendement de l'allocation au dernier jour i
- `SIGNED_VOLUME_{i}` Avec i dans 1,...,20 - Le volume signé de l'allocation au dernier jour i. Définition plus bas.
- `MEDIAN_DAILY_TURNOVER` - Turnover médian de l'allocation. Définition plus bas.
- `GROUP` - Un groupe anonymisé auquel appartient l'allocation.
- `TARGET` - Le rendement futur de l'allocation.

Plus de détails à propos des Volumes, Poids et Turnover.

A chaque jour `t` , chaque allocation `S` respecte cette propriété (dans un univers de `M` instruments de trading) :

$$\forall t\ ,\ \forall S : \quad \sum_{i=1}^{M} |w_{S,i,t}| = 1$$

Le **Volume signé (SIGNED_VOLUME)** d'une allocation `S` à `t` est donné par :

$$V_{S,t} = \sum_{i=1}^{M} w_{S,t,i} * V_{i,t}$$

Où `V_{i,t}` est le volumé total échangé sur le marché de l'instrument `i` lors de la session de trading au timestamp `t` .
Pour homogénéiser, ces `V_{S,t}` ont été rescalés de manière "roulante" pour assurer la comparabilité entre différents styles d'allocations.

Le `MEDIAN_DAILY_TURNOVER` d'une allocation `S` à `t` est donné par :

$$TO_{S,t} = TURNOVER_{S,t} = \sum_{i=1}^{M} |w_{S,t,i} - w_{S,t-1,i}|$$

$$MDT_{S,t} = median(TO_{S,t}, TO_{S,t-1}, \ldots, TO_{S,t-20})$$

Fichiers

Tous les fichiers sont indéxés par un unique ROW_ID, faisant référence à un unique tuple (date, allocation), permettant de mapper X_train avec Y_train

- **X_train.csv** - Les données d'entrainement
- **y_train.csv** - La target d'entrainement
- **X_test.csv** - Les données de test
- **sample_submission.csv** - un fichier de soumissions aléatoire, dans le format attendu
- **benchmark_submission.ipynb** - Un notebook benchmark pour générer la soumission benchmark dans le leaderboard.

Il y a 527073 observations (i.e. lignes) dans les données d'entrainement, 31870 obsevations dans les données de test.

Description du benchmark

Un notebook benchmark est donné dans la section data pour générer la soumission "benchmark" visible dans le leaderboard.

Ce notebook permet aussi de voir comment générer un fichier de soumission au bon format.

Ce notebook contient plusieurs parties :

- Construction de features additionnelles représentant la moyenne journalière des performances passées des allocations à différents horizons
- Construction de features additionnelles représentant la moyenne journalière des performances passées de toutes les allocations à différents horizons
- Construction de features additionnelles représentant la volatilité passée des allocations sur les 20 derniers jours
- Construction de features additionnelles représentant la moyenne des volatilités passées des allocations sur les 20 derniers jours
- Un ridge calibré sur toutes les features (base + additionnelles).
- Un modèle lightgbm calibré sur toutes les features (base + additionnelles), avec une section cross validation (prédictions soumises en tant que benchmark).

Le score public, visible sur le leaderboard, du modèle lgbm est de 0.5079.

Fichiers

Les fichiers sont accessibles une fois connecté et inscrit au challenge

L'organisateur du challenge

Qube Research & Technologies (QRT) is a global quantitative and systematic investment manager, operating in all asset classes across the world. Driven by a shared passion for data, research, technology and trading expertise, we strive to deliver high-quality returns for our investors. Established in 2018, QRT can rely on its 2 000+ employees across 16 offices globally. QRT supports various coding initiatives as well as academic projects developing and promoting maths and science education.

SITE WEB DE L'ORGANISATEUR

Challenge data est soutenu par :